

DATA CHALLENGE II · PARTIE III

Université

de Strasbourg

Génération de Données Synthétiques

Méthode Avatar — Guillaudeux et al., 2023

ASAS Nedah
MUGISHA Abelard
DURIMEL Yohaldere

L'Objectif

Créer une cohorte de patients virtuels qui n'existent pas, mais qui conservent les mêmes caractéristiques statistiques que les vrais.

UTILITÉ

- ✓ Réalisme statistique des distributions
- ✓ Préservation des corrélations médicales
- ✓ Conservation des profils atypiques
- ✓ Lien clinique âge / coûts maintenu

vs

CONFIDENTIALITÉ

- ✓ Aucun avatar ne copie un vrai patient
- ✓ Distance sécuritaire aux données réelles
- ✓ Anonymat mathématiquement garanti

Approche locale et centrée sur le patient — contrairement aux méthodes globales qui lissent les profils rares

1

Sélection du patient

L'algorithme sélectionne chaque vrai patient du fichier dans l'espace standardisé.

2

k plus proches voisins

Il identifie les sosies statistiques : même âge, mêmes coûts, même type d'asthme.

3

Barycentre = Avatar

Fusion mathématique des sosies.
Réaliste, mais clone de personne.
L'anonymat est assuré.

L'avatar se situe toujours entre de vrais patients — jamais une copie exacte, jamais une valeur inventée.

Étape 1a — Préparation et Application

SimpleImputer · stratégie médiane

Python · pandas / scikit-learn

```
df_real = pd.read_csv(
    'trainDataDC2.csv.gz',
    na_values='NA'
)

# Imputation par la MÉDIANE
imputer = SimpleImputer(
    strategy='median'
)
X_imputed = imputer.fit_transform(
    df_features
)
```

na_values='NA'

Les textes 'NA' sont reconnus comme valeurs manquantes, non comme chaînes de caractères.

Pourquoi la médiane ?

Les coûts médicaux ont des outliers très élevés. La médiane est insensible aux cas extrêmes contrairement à la moyenne.

Étape 1b — Standardisation

Une obligation mathématique absolue pour le k-NN

$$x_{std} = (x - \mu) / \sigma$$

Variable	Plage	Sans standardisation	Avec StandardScaler
Âge patient	0 – 100 ans	Écrasé par les coûts	Poids équilibré
Coûts médicaux	0 – 20 000 \$	Domine tout le calcul	Poids équilibré

Python • StandardScaler

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_imputed)
# → Moyenne=0, Écart-type=1 pour chaque variable
```

Résultat : un écart d'un an d'âge pèse exactement autant qu'un écart d'un dollar de coûts. L'algorithme voit le profil clinique complet non pas la facture.

Étape 2 — L'Hyperparamètre k

Le curseur entre Utilité et Confidentialité

k = 2

Trop faible

Points positifs

- ✓ Utilité excellente
- ✓ Distributions très fidèles

Points négatifs

- ✗ Confidentialité médiocre
- ✗ Avatar quasi-identique au patient

k = 5

Notre choix ✓

Points positifs

- ✓ Utilité statistique préservée
- ✓ Corrélations maintenues
- ✓ Anonymat suffisant (DCR=0.88)
- ✓ Conforme aux recommandations

k = 15

Trop élevé

Points positifs

- ✓ Anonymat très fort
- ✓ Aucune copie possible

Points négatifs

- ✗ Corrélations détruites
- ✗ Utilité médicale effondrée

Étape 2 — Algorithme k-NN et Loi de Dirichlet

La boucle de génération des avatars

Python · scikit-learn / numpy

```
K_VOISINS = 5

knn = NearestNeighbors(
    n_neighbors=K_VOISINS
)
knn.fit(X_scaled)

distances, indices = knn.kneighbors(
    X_scaled
)

X_synth_scaled = np.zeros_like(X_scaled)

for i in range(len(X_scaled)):
    voisins = X_scaled[indices[i]]

    poids = np.random.dirichlet(
        np.ones(K_VOISINS)
    )

    X_synth_scaled[i] = np.dot(
        poids, voisins
    )
```

k = 5 voisins

Notre hyperparamètre. Identifie les 5 sosies de chaque patient dans l'espace standardisé.

Loi de Dirichlet

$\text{np.ones}(k)$ = distribution symétrique. Aucun voisin favorisé. Génère des poids aléatoires dont la somme = 1 exactement.

np.dot = barycentre

Produit matriciel : combinaison pondérée des 5 voisins. C'est notre patient synthétique.

Étape 3 — Post-traitement

Ramener les mathématiques à la réalité clinique

Un barycentre dans un espace abstrait peut produire un âge de -4 ans ou une probabilité de 0.65 pour une variable binaire. Le post-traitement corrige cela.



Étape 0 — Dé-standardisation (`inverse_transform`)

Retour aux unités réelles : années, dollars, jours. Les chiffres redeviennent interprétables.



Contrainte des bornes (`np.maximum`)

Un âge ou un coût ne peut descendre en-dessous du minimum observé dans la réalité. Impossible d'avoir un âge de -4 ans.



Variables indicatrices (binaires)

`round() + clip(0,1)` — La pneumonie ou la rhinite sont 0 ou 1. L'avatar peut sortir à 0.65 . On arrondit et on bloque.



Variables de comptage entières

`round()` — On ne fait pas 2.3 crises d'asthme. Arrondi entier pour `pre_asthma_days`, exacerbations, etc.

Identifiants factices débutant à 1 000 000 — évite toute confusion avec les vrais patients.

Évaluation — L'Utilité des Données Synthétiques

Deux métriques complémentaires

A

Distance de Wasserstein

Utilité univariée

0.0975

plus bas = mieux

Mesure l'effort nécessaire pour transformer la distribution synthétique en distribution réelle. Une valeur proche de 0 signifie que les courbes se superposent parfaitement.

Normalisation par l'écart-type pour comparer les variables entre elles. Moyenne calculée sur toutes les colonnes.

B

Différence des Corrélations

Utilité multivariée

0.0105

≈ 1 pt d'écart moyen

Il ne suffit pas que chaque variable soit correcte. La logique clinique doit être respectée : un patient avec de nombreux jours de traitement doit avoir des coûts plus élevés.

Matrice de corrélation calculée après imputation. Écart MAE moyen entre matrice réelle et synthétique.

Évaluation — La Confidentialité (DCR)

Distance to Closest Record · sous-échantillon 500

Comment ça marche ?

Pour chaque avatar, le script calcule la distance euclidienne qui le sépare du vrai patient qui lui ressemble le plus dans la base réelle.

Distance to Closest Record

0.8780

plus haut = mieux

Si distance ≈ 0

L'avatar est un clone. La vie privée est violée et le fichier n'est pas publiable.

Interprétation du résultat — DCR = 0.8780

La loi de Dirichlet a suffisamment bien mélangé nos 5 voisins pour créer un point totalement isolé dans l'espace. Le bouclier de l'anonymat est étanche.

Calcul réalisé sur un sous-échantillon de 500 individus pour des raisons de coût computationnel (matrice de distances en $O(n^2)$).

Conclusion

Problème résolu

Des patients virtuels construits localement — k voisins, loi de Dirichlet, barycentre — qui n'exposent aucun individu réel.

Utilité démontrée

Wasserstein = 0.0975 · Δ corrélations = 0.0105 — les propriétés statistiques et la logique clinique sont préservées.

Confidentialité assurée

DCR = 0.8780 — la loi de Dirichlet maintient chaque avatar à distance sécuritaire des patients réels.

Un compromis satisfaisant

syntheticDataDC2.csv : adapté pour la recherche médicale, sans jamais compromettre le secret médical.

Merci pour votre attention
